MODUL PRAKTIKUM BAB 9

ARIMAX DAN VECTOR AUTOREGRESSION (VAR)

1. Tujuan dan Desain

Aspek	Ketentuan
Dataset	240 bulan, Januari 2006–Desember 2025; seluruh angka SIMULASI, bukan data BPS/BI
Target bersama	harga_pangan
Prediktor eksogen ARIMAX	biaya_energi; curah_hujan_anomali
Variabel endogen VAR	harga_pangan; produksi_pangan; inflasi_pangan
Pemisahan	Train 216 bulan (2006–2023); test 24 bulan (2024–2025)
Lingkungan	Google Colab / Python statsmodels, pandas, matplotlib, sklearn

Tujuan: mahasiswa mampu membedakan variabel eksogen dan endogen; membangun ARIMAX dan VAR; menguji asumsi, memeriksa residual, menafsirkan dinamika VAR secara prediktif; membandingkan MAE/RMSE pada target dan horizon yang sama; serta menjelaskan batasan future X.

2. Landasan model dan notasi

ARIMAX: regresi dengan galat ARIMA

$y_t = \beta_0 + \beta_1 x_{1,t} + \beta_2 x_{2,t} + \eta_t$; $\varphi(B)(1 - B)^d \eta_t = \theta(B)\varepsilon_t$.

$B\eta_t = \eta_{t-1}$; $\varphi(B)=1-\varphi_1 B-\cdots-\varphi_p B^p$; $\theta(B)=1+\theta_1 B+\cdots+\theta q B q$. ε_t adalah inovasi white noise. Koefisien X menunjukkan asosiasi kondisional, bukan bukti sebab-akibat. Future X harus diketahui, diramalkan secara terpisah, atau ditetapkan sebagai skenario.

VAR(p): sistem endogen

$y_t = c + A_1 y_{t-1} + \cdots + A_p y_{t-p} + \varepsilon_t$; $y_t = [\text{harga, produksi, inflasi}]^T$.

A_j berukuran 3×3. Untuk VAR(p) dengan intercept, jumlah koefisien sistem = $K + pK^2$ (di luar kovarians inovasi). VAR memprediksi seluruh variabel secara bersama, tetapi tidak otomatis membuktikan hubungan kausal.

Evaluasi: MAE = $(1/n)\Sigma|y_t-\hat{y}_t|$; RMSE = $\sqrt{[(1/n)\Sigma(y_t-\hat{y}_t)^2]}$. Keduanya dihitung pada 24 observasi test yang sama.

3. Petunjuk Colab dan berkas

Unggah dataset_ekonomi_ARIMAX_VAR_240_bulan.csv ketika diminta. Notebook pendamping berisi empat percobaan yang sama seperti kode lengkap di bawah. Nama file upload boleh berubah (mis. (1)); kode membaca nama yang benar-benar diunggah. Jalankan sel dari awal hingga akhir. Tidak memerlukan mount Google Drive.

4.1 Percobaan 1: EDA, pembagian kronologis, stasioneritas

Tujuan dan langkah: Mengenal lima variabel ekonomi sintetis, memeriksa data hilang dan pola serial, memisahkan train-test, serta menguji ADF hanya pada train.

Kode Python: jalankan sebagai satu sel Colab

```
import numpy as np, pandas as pd, matplotlib.pyplot as plt
from google.colab import files
from statsmodels.tsa.stattools import adfuller
from statsmodels.tsa.statespace.sarimax import SARIMAX
from statsmodels.tsa.api import VAR
from statsmodels.stats.diagnostic import acorr_ljungbox
from sklearn.metrics import mean_absolute_error, mean_squared_error
uploaded = files.upload()
filename = next(iter(uploaded))
df                              =                              pd.read_csv(filename,
parse_dates=['date']).set_index('date').sort_index().asfreq('MS')
expected                                                                        =
['harga_pangan','produksi_pangan','inflasi_pangan','biaya_energi','curah_hujan
_anomali']
assert  set(expected).issubset(df.columns),  f'Kolom  kurang:  {set(expected)-
set(df.columns)}'
assert len(df)==240 and df[expected].notna().all().all(), 'Periksa jumlah baris
dan missing value'
df=df[expected]
display(df.head()); display(df.describe().round(3))
df.plot(subplots=True,  figsize=(11,10),  title='Indeks  ekonomi  sintetis');
plt.tight_layout();plt.show()
print('Korelasi deskriptif (bukan kausal):');display(df.corr().round(2))
h=24;train=df.iloc[:-h];test=df.iloc[-h:]
print('TRAIN:',train.index.min(),train.index.max(),len(train))
print('TEST :',test.index.min(),test.index.max(),len(test))
def adf_table(data):
    return
pd.DataFrame([{'variabel':c,'ADF':adfuller(data[c],autolag='AIC')[0],
      'p_value':adfuller(data[c],autolag='AIC')[1]} for c in data.columns])
display(adf_table(train).round(4))
```

Pertanyaan analisis dan interpretasi

Apa makna H_0 pada ADF? Apakah seluruh variabel layak dimodelkan pada level? Jika ada p≥0,05, jelaskan pemeriksaan lanjutan sebelum memilih differencing.

4.2 Percobaan 2: ARIMA baseline dan ARIMAX

Tujuan dan langkah: Bangun kandidat ARIMA tanpa X dan ARIMAX dengan X, pilih berdasarkan AIC train dan diagnostik, evaluasi ramalan bersyarat pada X test (oracle), lalu buat skenario future X.

Kode Python: jalankan sebagai satu sel Colab

```
ycol='harga_pangan';xcols=['biaya_energi','curah_hujan_anomali']
orders=[(0,0,0),(1,0,0),(2,0,0),(1,0,1)]
models={};rows=[]
for order in orders:
    for use_x in [False,True]:
        name=('ARIMAX' if use_x else 'ARIMA')+str(order)
        try:
            fit=SARIMAX(train[ycol],exog=train[xcols] if use_x else None,
                order=order,trend='c',enforce_stationarity=True,
                enforce_invertibility=True).fit(disp=False,maxiter=250)
            models[name]=fit

rows.append({'model':name,'with_X':use_x,'AIC':fit.aic,'BIC':fit.bic})
        except Exception as err:print('Gagal',name,err)
rank=pd.DataFrame(rows).sort_values('AIC');display(rank.round(2))
name_ax=rank.loc[rank.with_X,'model'].iloc[0]
name_ar=rank.loc[~rank.with_X,'model'].iloc[0]
fit_ax=models[name_ax];fit_ar=models[name_ar]
print('ARIMAX:',name_ax);print(fit_ax.summary())
print('Ljung-Box
ARIMAX:');display(acorr_ljungbox(fit_ax.resid.iloc[5:],lags=[6,12],return_df=T
rue))
# PERHATIAN: X aktual di TEST adalah evaluasi oracle, bukan forecast
operasional!
pred_ax=np.asarray(fit_ax.get_forecast(steps=h,exog=test[xcols]).predicted_mea
n)
pred_ar=np.asarray(fit_ar.get_forecast(steps=h).predicted_mean)
pred_naive=np.repeat(train[ycol].iloc[-1],h)
def metrics(y,p):return
{'MAE':mean_absolute_error(y,p),'RMSE':np.sqrt(mean_squared_error(y,p))}
for nm,pred in [('ARIMAX (oracle
X)',pred_ax),('ARIMA',pred_ar),('Naive',pred_naive)]:
    print(nm,metrics(test[ycol],pred))
plt.figure(figsize=(11,4));plt.plot(test.index,test[ycol],label='Aktual')
plt.plot(test.index,pred_ax,label='ARIMAX (oracle
X)');plt.plot(test.index,pred_ar,label='ARIMA')
plt.legend();plt.title('Test 24 bulan — perbandingan kondisional');plt.show()
```

```
future_x=pd.DataFrame(np.tile(train[xcols].iloc[-
1].to_numpy(),(h,1)),index=test.index,columns=xcols)
future_x_alt=future_x.copy();future_x_alt['biaya_energi']+=1
scenario_0=fit_ax.get_forecast(steps=h,exog=future_x).predicted_mean
scenario_1=fit_ax.get_forecast(steps=h,exog=future_x_alt).predicted_mean
plt.figure(figsize=(11,4));plt.plot(scenario_0.index,scenario_0,label='Energi
tetap')
plt.plot(scenario_1.index,scenario_1,label='Energi +1
indeks');plt.legend();plt.show()
```

Pertanyaan analisis dan interpretasi

Bandingkan koefisien X dan diagnostik. Jelaskan mengapa nilai X test tidak boleh dianggap tersedia otomatis saat origin ramalan.

4.3 Percobaan 3: VAR, Granger, IRF dan FEVD

Tujuan dan langkah: Modelkan tiga variabel endogen bersama; pilih lag, periksa stabilitas dan residual, lalu interpretasikan hubungan prediktif dan respons shock.

Kode Python: jalankan sebagai satu sel Colab

```
vcols=['harga_pangan','produksi_pangan','inflasi_pangan']
vm=VAR(train[vcols]);selection=vm.select_order(maxlags=8)
print(selection.summary());p=max(1,int(selection.selected_orders.get('bic') or
1))
fit_var=vm.fit(p);print('Lag p =',p);print(fit_var.summary())
print('VAR stabil:',fit_var.is_stable())
print(fit_var.test_whiteness(nlags=max(12,p+3)).summary())
print('Granger: produksi -> harga')
print(fit_var.test_causality('harga_pangan',['produksi_pangan'],kind='f').summ
ary())
print('Granger: harga -> produksi')
print(fit_var.test_causality('produksi_pangan',['harga_pangan'],kind='f').summ
ary())
irf=fit_var.irf(12);irf.plot(orth=True);plt.show()
fevd=fit_var.fevd(12);print(fevd.summary());fevd.plot();plt.show()
pred_var=pd.DataFrame(fit_var.forecast(train[vcols].values[-p:],steps=h),
    index=test.index,columns=vcols)
print('Forecast VAR (harga):',metrics(test[ycol],pred_var[ycol]))
```

Pertanyaan analisis dan interpretasi

Apakah produksi Granger-memprediksi harga? Apa arti IRF/FEVD dan mengapa ordering pada orthogonalized IRF perlu justifikasi?

4.4 Percobaan 4: Perbandingan ARIMAX vs VAR

Tujuan dan langkah: Bandingkan pada target harga_pangan dan horizon test yang identik. ARIMAX oracle X ditampilkan terpisah agar tidak salah diklaim sebagai evaluasi operasional. Bandingkan pula baseline.

Kode Python: jalankan sebagai satu sel Colab

```
compare=pd.DataFrame([
 {'metode':'Naive','akses_future_X':'Tidak','forecast':pred_naive},
 {'metode':'ARIMA','akses_future_X':'Tidak','forecast':pred_ar},
 {'metode':'VAR','akses_future_X':'Tidak; prediksi endogen
rekursif','forecast':pred_var[ycol].to_numpy()},
 {'metode':'ARIMAX oracle','akses_future_X':'Ya, X aktual TEST (tidak
operasional)','forecast':pred_ax},
 {'metode':'ARIMAX skenario','akses_future_X':'Skenario X
konstan','forecast':np.asarray(scenario_0)}])
results=[]
for _,r in compare.iterrows():
    results.append({'metode':r['metode'],'asumsi_X':r['akses_future_X'],
        **metrics(test[ycol],r['forecast'])})
comparison=pd.DataFrame(results).sort_values('RMSE')
display(comparison.round(3))
plt.figure(figsize=(12,5));plt.plot(test.index,test[ycol],label='Aktual',lw=2)
plt.plot(test.index,pred_var[ycol],label='VAR');plt.plot(test.index,pred_ax,la
bel='ARIMAX oracle X')
plt.plot(test.index,scenario_0,label='ARIMAX skenario X',ls='--')
plt.plot(test.index,pred_ar,label='ARIMA',alpha=.75)
plt.legend();plt.title('Target dan test identik; asumsi informasi
berbeda');plt.show()
print('Selisih RMSE ARIMAX oracle vs VAR:',
      metrics(test[ycol],pred_ax)['RMSE']-
metrics(test[ycol],pred_var[ycol])['RMSE'])
```

Pertanyaan analisis dan interpretasi

Apakah ARIMAX lebih akurat daripada VAR? Jawab berdasarkan tabel, namun jelaskan bahwa ARIMAX oracle memiliki informasi masa depan yang tidak tersedia bagi VAR. Metode mana yang Anda pilih untuk prediksi operasional?

Kelebihan dan kelemahan yang wajib dibahas

Metode	Kelebihan	Kelemahan / syarat
ARIMAX	Memanfaatkan faktor luar; interpretasi koefisien X; simulasi kebijakan/skenario.	Perlu X masa depan; eksogenitas perlu justifikasi; risiko bias jika X dipengaruhi Y.
VAR	Memodelkan interaksi lag dan feedback; forecast bersama; Granger, IRF, FEVD.	Parameter meningkat cepat; butuh data cukup dan stabil; IRF/FEVD sensitif identifikasi shock.
Kesimpulan adil	Pilih berdasarkan RMSE/MAE pada horizon dan informasi yang sama.	ARIMAX oracle X tidak boleh dianggap menang operasional tanpa mekanisme forecast X.

5. Laporan praktikum

Mahasiswa dapat menggunakan dataset yang bersumber dari Badan Pusat Statistik (BPS), portal Open Data, Kaggle, maupun sumber lain yang relevan dan dapat dipertanggungjawabkan. Dataset harus memiliki variabel dan periode pengamatan yang memadai untuk penerapan metode ARIMAX dan VAR.

Laporan praktikum sekurang-kurangnya memuat:

1. Identitas dan eksplorasi dataset: sumber data, deskripsi variabel, periode pengamatan, serta visualisasi deret waktu.
2. Pengujian stasioneritas: hasil uji ADF dan dasar pengambilan keputusan penggunaan data level atau differencing.
3. Pemodelan ARIMAX: spesifikasi model, estimasi parameter, dan interpretasi hasil.
4. Pemodelan VAR: pemilihan lag optimal, pengujian stabilitas, Granger causality, Impulse Response Function (IRF), dan Forecast Error Variance Decomposition (FEVD).
5. Evaluasi peramalan: tabel perbandingan MAE dan RMSE untuk variabel target harga menggunakan kedua metode.

6. Referensi

1. Hyndman & Athanasopoulos (2021), Forecasting: Principles and Practice, Bab 10 dan 12.3. Lütkepohl (2005), New Introduction to Multiple Time Series Analysis. Statsmodels: SARIMAX dan VAR API.
2. Materi PPTX Bab 9 ARIMAX–VAR (versi yang digunakan dalam perkuliahan).